

Mestrado em Informática
Pós-Graduação em Data Science and Digital Transformation
(Ambientes de) Programação para Ciência de Dados
Projeto 2

INTRODUÇÃO

A análise de dados desempenha um papel fundamental na compreensão de fenómenos complexos e no apoio à tomada de decisão informada. No contexto do ensino superior, a análise dos dados académicos dos estudantes pode contribuir para a identificação precoce de padrões associados ao sucesso académico, abandono ou prolongamento dos estudos.

Neste projeto, será utilizado um conjunto de dados anonimizados relativo à situação académica de estudantes de cursos de Licenciatura do Instituto Politécnico de Portalegre, contendo informação disponível no momento da matrícula. O objetivo final é analisar e preparar os dados para a futura construção de modelos de aprendizagem máquina capazes de prever, o mais cedo possível no percurso académico, a situação do estudante ao fim de N anos.

CONJUNTO DE DADOS

O conjunto de dados anonimizados encontra-se no ficheiro **dataset_PIAES_reduced.xlsx**.

As características presentes no conjunto de dados dizem respeito a uma parte da informação existente sobre os estudantes no ato da matrícula, nomeadamente:

Sexo (M/F)

Estado civil (desc)

Ordem de ingresso (opção de preferência de ingresso no curso – 1 representa 1ª opção)

Curso (desc)

Deslocado (S/N)

Nacionalidade (desc)

Habilitação literária mãe (desc)

Situação profissional mãe (desc)

Situação profissional pai (desc)

Nota ingresso

Bolseiro (1 para detentor de bolsa, 0 para o caso contrário)

Idade no ingresso

O campo **Categoria** tem como valores possíveis **Diplomado / Não Diplomado** e indica se o estudante obteve ou não o seu diploma ao fim de N anos de frequência do curso de Licenciatura. N representa a duração de um ciclo de estudos, e tem valor 4 para a Licenciatura em Enfermagem, valor 3 para todos os outros cursos de Licenciatura do IPP.

Na categoria “Não Diplomado” estão incluídos os estudantes que, estando inscritos, ainda não terminaram os seus cursos ao fim de N anos, e também os estudantes que abandonaram o curso ao longo do seu percurso académico.

Parte 1 — Caracterização inicial dos dados

1. Apresente uma caracterização geral do conjunto de dados: número de observações e de atributos; tipos de variáveis (numéricas, categóricas, binárias).
2. Analise a distribuição da variável **Categoria**. O conjunto de dados encontra-se desbalanceado? Discuta as possíveis implicações desse desbalanceamento numa análise futura.

Parte 2 — Análise exploratória

1. Selecione três variáveis (pelo menos uma numérica e uma categórica) e analise as suas distribuições, procurando identificar padrões ou comportamentos relevantes.

2. Analise a relação entre essas variáveis e a variável Categoria, dizendo se existem diferenças visíveis entre estudantes Diplomados e Não Diplomados.
3. Alguma das variáveis parece(m) ser mais promissoras para distinguir os dois grupos?

Parte 3 — Qualidade dos dados

Identifique e trate valores em falta, possíveis inconsistências, outliers em variáveis numéricas, ou outros aspetos considerados relevantes. Para cada problema identificado justifique a estratégia de tratamento adotada, explicando, sempre que possível, porque é a decisão adequada no contexto.

Parte 4 — Preparação dos dados

1. Prepare o conjunto de dados para uma futura fase de modelação: converta variáveis categóricas em formato numérico; aplique técnicas de normalização ou padronização a variáveis numéricas. Justifique as escolhas efetuadas.
2. Aplique uma técnica de tratamento de dados desbalanceados, comparando a distribuição antes e depois. Discuta as vantagens e riscos da abordagem escolhida neste problema concreto.

Parte 5 — Visualização e storytelling

Nesta parte do trabalho pretende-se sintetizar os principais resultados da análise através de visualizações interativas adequadas e construir uma narrativa clara que permita compreender o perfil dos estudantes e os fatores potencialmente associados ao sucesso académico.

Para o efeito, deverá utilizar o Looker Studio, com o objetivo de:

- Comunicar de forma clara e intuitiva os padrões identificados nos dados;
- Apoiar a interpretação dos resultados obtidos nas fases de análise exploratória e preparação dos dados;
- Criar uma base visual interativa que suporte decisões;
- Estabelecer uma narrativa coerente que apoie a tomada de decisão informada.

Deve organizar os dashboards nas áreas que entender mais relevantes (caracterização global dos estudantes, comparação entre diplomados e não diplomados, análise de fatores potencialmente associados ao sucesso académico, etc).

Sempre que possível, deverão ser utilizados filtros globais adequados (por exemplo, Curso ou Categoria) para permitir uma análise interativa e direcionada.

Entrega e discussão

A componente do projeto relativa às partes 1 a 4 será entregue pelo PAE, sob a forma de Jupyter Notebook, contendo a identificação do estudante, o código comentado, os resultados intermédios, e as explicações e análise aos resultados e/ou resposta às questões usando as células *markdown*.

A Parte 5, referente à visualização e storytelling, deve ser partilhada através da funcionalidade de partilha do Looker Studio com mvmartins@ipportalegre.pt e vrealinho@ipportalegre.pt.

O trabalho entregue é sujeito a discussão oral em data a combinar.

CrITÉrios de avaliação

- Correção técnica e uso adequado das ferramentas
- Qualidade da análise efetuada
- Clareza e coerência das justificações
- Qualidade e adequação das visualizações
- Capacidade de interpretação crítica dos resultados
- Clareza do storytelling e da comunicação escrita